1. 单细胞 RNA 测序数据过滤前的质量评估

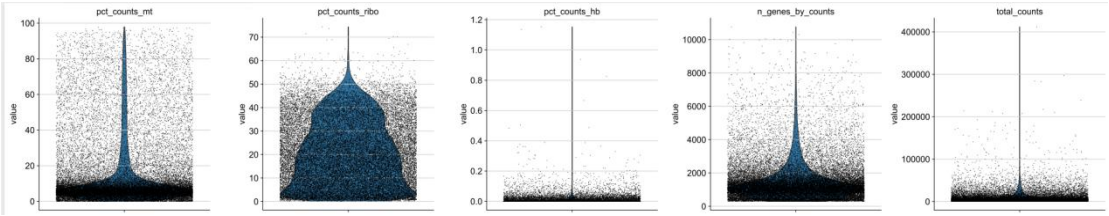

(A) 细胞中线粒体基因表达百分比分布，显示高线粒体含量的异常细胞群体
(B) 核糖体基因表达百分比呈钟型分布，反映细胞翻译活性
(C) 血红蛋白基因表达百分比，评估红细胞污染程度
(D) 每个细胞检测到的基因数分布，显示细胞复杂度异质性
(E) 每个细胞的总 UMI 计数分布，反映细胞 RNA 含量差异

2. 应用严格质量控制标准后的数据质量评估

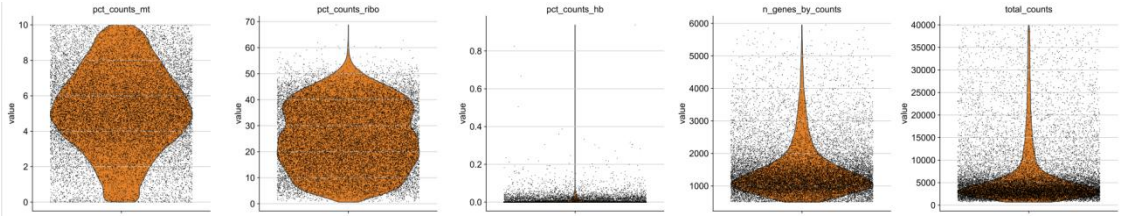

(A) 过滤后线粒体基因百分比分布改善，高异常值细胞被移除
(B) 核糖体基因表达分布保持生物学相关变异
(C) 血红蛋白基因表达维持在可接受范围内
(D) 基因检测数分布更加集中，去除了极端值
(E) UMI 计数分布更加规范，高质量细胞富集，提高了数据均一性

3. 细胞总 UMI 计数与基因数相关性散点图（验证质控效果）

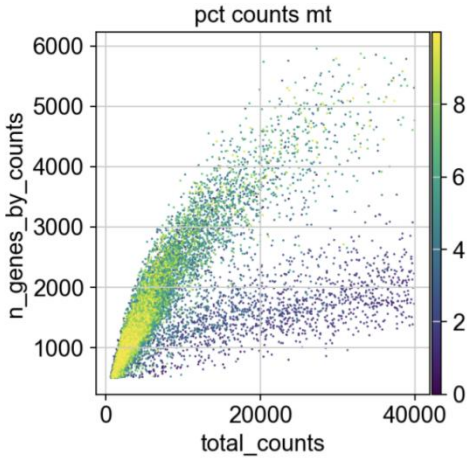

散点图显示质控过滤后绝大多数细胞呈现高质量特征（黄绿色，高 UMI/基因数，低线粒体比例），符合生物学预期。仅的细胞（蓝紫色）显示高线粒体比例特征，表明质控策略有效保留了高质量细胞群体，残留的少量应激细胞对整体数据分析影响有限。

4.标准化前后的高变基因散点图

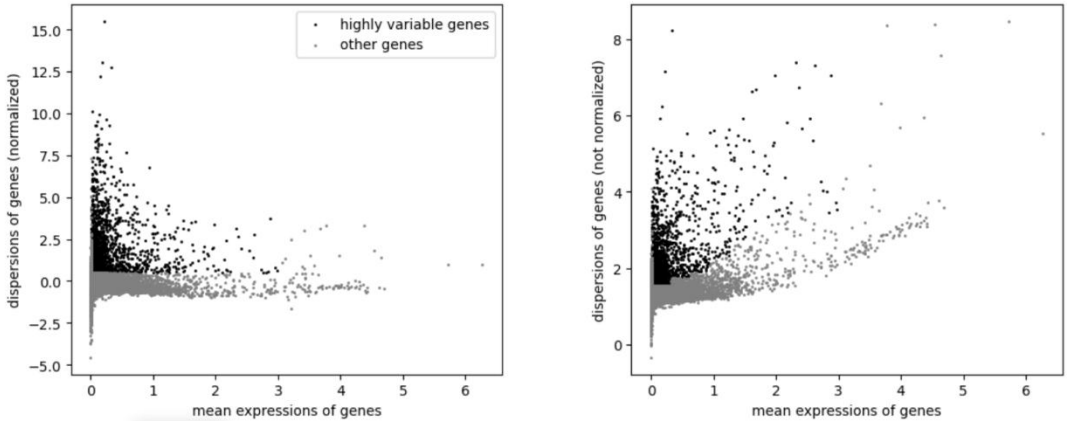

A.标准化的基因离散度与平均表达量的关系：标准化成功消除技术变异，离散度与表达量无关；垂直分界表明高变基因反映真实生物学差异；适合下游分析
B.未标准化后的基因离散度与平均表达量的关系：离散度与表达量强相关（弧形分界）；技术变异主导，可能误选高表达基因为"高变"；影响分析准确性
结论： 标准化后数据质量显著改善，应选用左图标准进行后续分析。

5.细胞周期基因 PCA：regress_out 前后对比

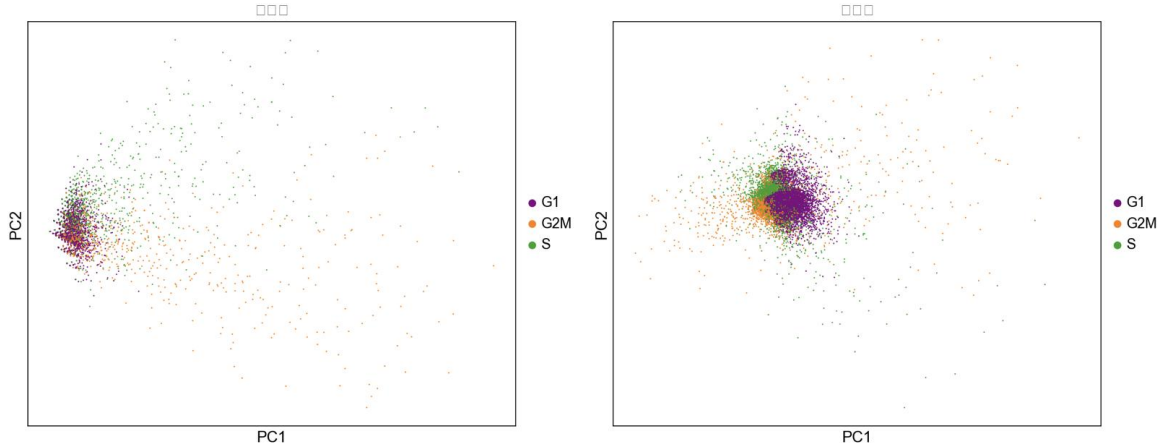

A. 移除前：PC1/PC2 主要受测序深度及批次影响，G1/S/G2M 三群沿 PC2 方向大致可辨，但存在明显重叠。
B.移除后：线性回归已抽走 S_score 与 G2M_score 带来的主要变异，周期基因剩余方差呈放射状分布；三群仍可见扇形分区，但不再沿单一轴排列，证明细胞周期效应已被有效削弱，可进入后续聚类分析。

6.PCA 碎石图：主成分方差比例

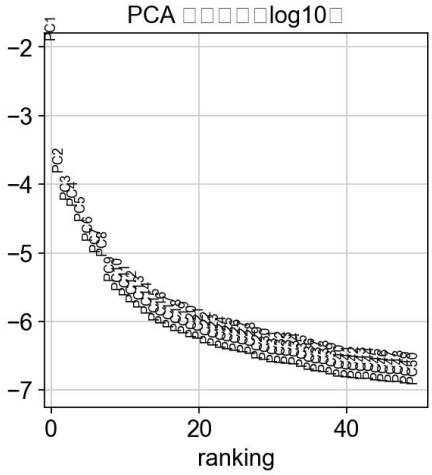

横坐标：主成分编号（PC1 → PC50）；纵坐标：该主成分解释的方差比例（log10 尺度）。

曲线在 PC≈8 处出现“拐弯”，此后方差比例下降趋平，说明 PC8 之后各主成分捕获的生物学信号已极少。因此下游邻域图计算选用前 8 个主成分即可保留主要信号并降低噪声。

7.PCA 质控检查：样本批次与线粒体含量

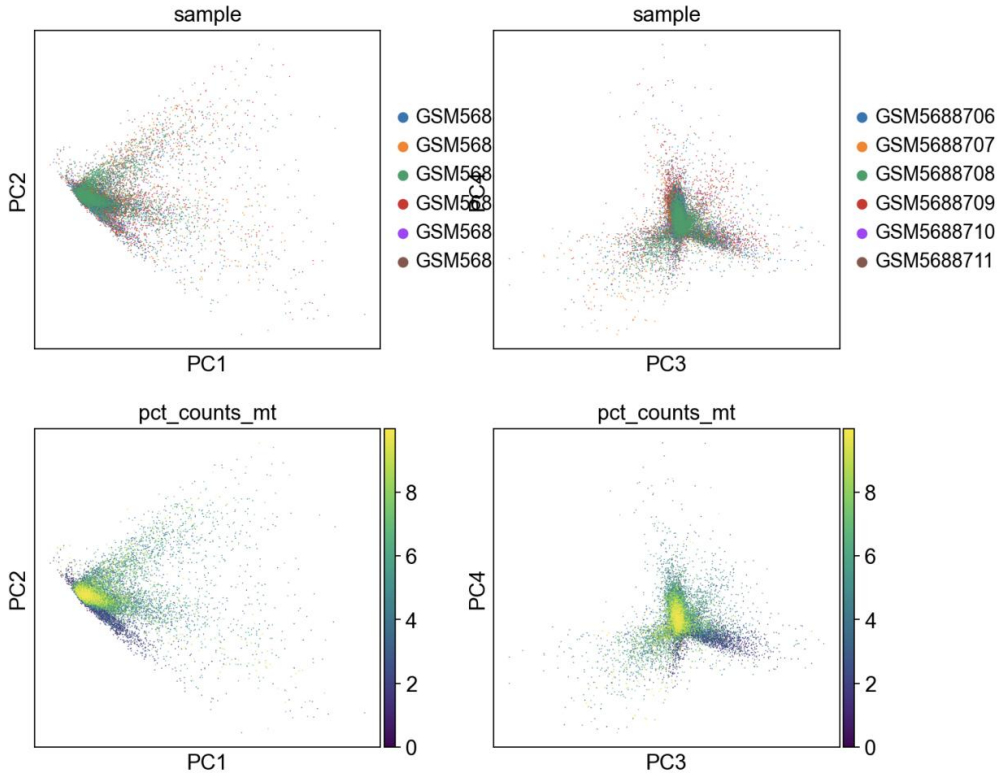

A-B.按样本 ID 上色，PC1 vs PC2 与 PC3 vs PC4；各批次细胞重叠度高，无明显批次驱动变异。

C-D.按线粒体基因百分比上色；高线粒体细胞随机散布，未沿任一主成分形成梯度，表明测序质量差异未对主成分构成主要影响。综合判断批次效应微弱，可直接进入下游聚类分析。

8. UMAP 批次质控图（n PCs = 15）

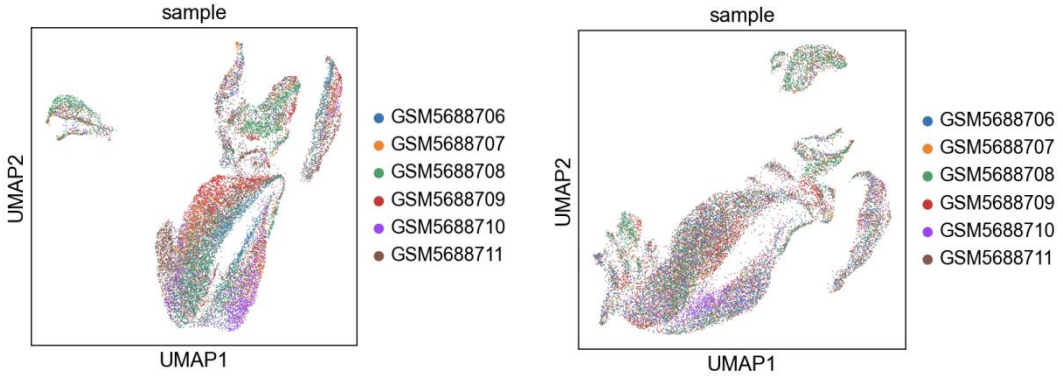

A. 使用原始 PCA 降维，UMAP 嵌入。不同颜色代表不同样本。可见样本间存在明显批次聚集，提示需批次校正。
B. 基于前 15 个主成分计算邻域图并执行 UMAP（min_dist=0.5）。6 个结直肠癌样本（不同颜色）细胞在二维空间内高度重叠，无明显批次孤岛，表明样本间技术差异未主导整体变异，可直接进行后续聚类与细胞类型注释。

9.多分辨率 Leiden 聚类可视化（Harmony 去批次后）

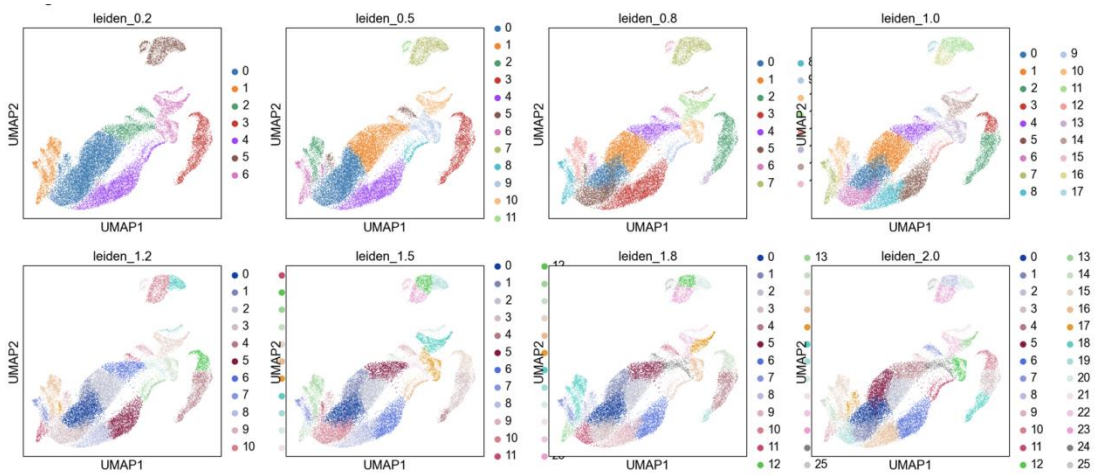

基于 Harmony 校正 PCA（8 PCs）构建 KNN 图，在 0.2 – 2.0 共 20 档分辨率下运行 Leiden 算法。UMAP 展示各分辨率对应的簇划分：随着分辨率升高，簇数量增加，边界逐渐细化。挑选原则为「块大小适中（200 – 3000 细胞）、边界可见、marker 基因可对应单一细胞类型」，后续将在 1.0 分辨率（示例）基础上进行细胞类型注释。

10.Harmony-UMAP 批次与双细胞质控

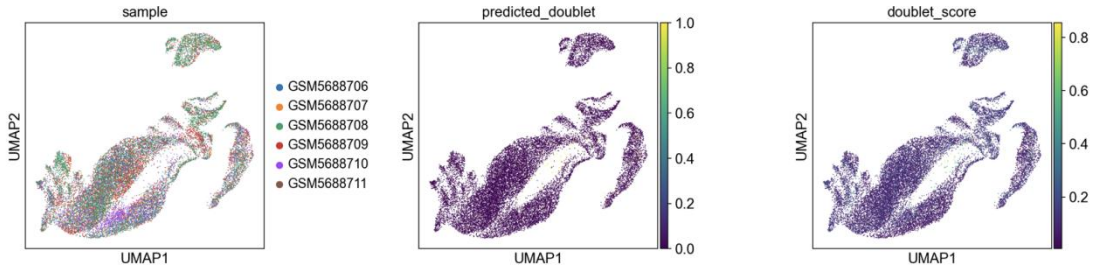

A.样本来源：6 例结直肠癌单细胞样本（不同颜色）经 Harmony 去批次后在 UMAP 上均匀混合，无整块孤岛，批次效应已有效消除。
B.预测双细胞：Scrublet 二分类结果，紫色为单细胞，深紫色为预测双细胞，无深紫大块聚集，仅零星散在，无需整簇删除。
C.双细胞连续打分：色阶右端（深紫）对应高打分，未见连续深紫带或大片高值区，高打分点零星分布且与 B 图位置一致，数据质量满足下游分析。

11.leiden_1.0 marker 基因点图（Harmony 去批次）

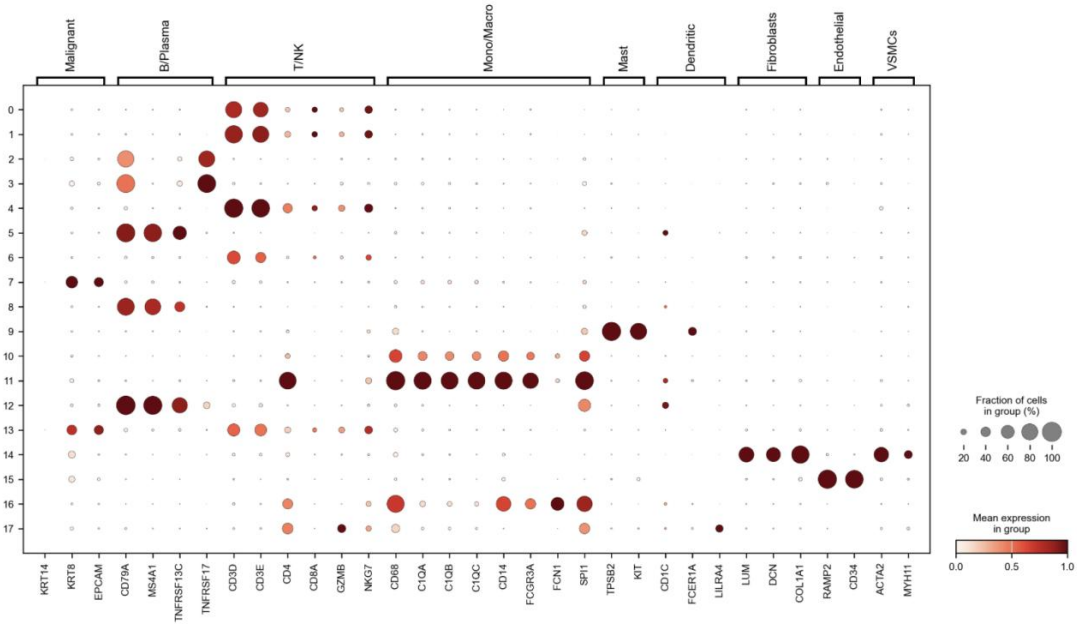

行：9 类细胞类型经典 marker 基因；列：leiden_1.0 分辨率下 16 个簇。
点大小：簇内阳性细胞比例；点颜色：标准化平均表达量（0-1）。
“大圆+深红”即高阳性+高表达，用于初步指派细胞身份；下调/上调分辨率细化至出现一簇一亮。

12.Leiden_1.0 差异基因点图（Top 5 DEG）

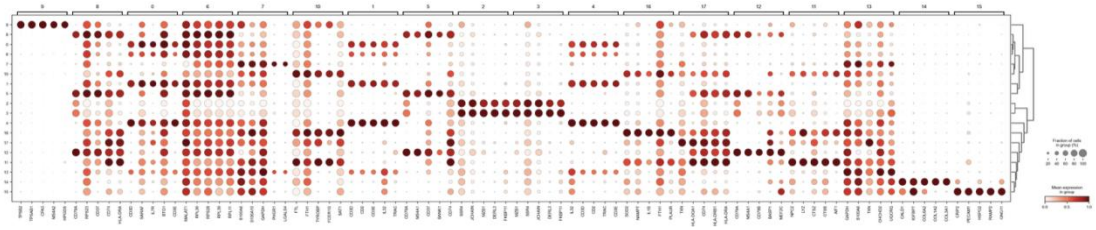

行：各簇 Top 5 显著 DEG（按 log2FC 排序）；列：16 个簇。
点大小：簇内表达该基因的细胞比例；点颜色：标准化平均表达量（0-1）。
基于 Wilcoxon 秩和检验，在 leiden_1.0 聚类结果中逐簇鉴定差异表达基因（DEG）。深紫+大圆即该簇最具特异性的新 marker，可用于细胞类型细化、功能通路后续分析。

13.细胞类型 UMAP 图（Leiden_1.0 聚类）

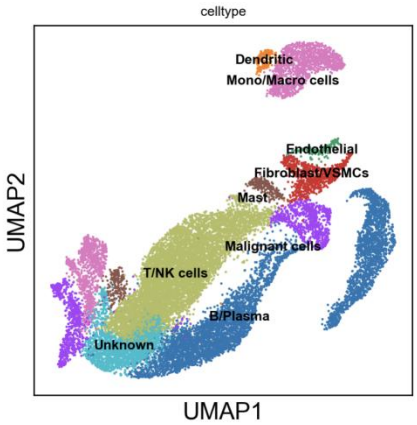

该图展示了基于 Leiden_0.9 聚类结果的单细胞 UMAP 可视化，每个点代表一个细胞，不同颜色对应不同的细胞类型。UMAP1 和 UMAP2 是两个降维后的坐标轴，用于在二维空间中展示高维数据的结构。

14.细胞类型注释验证：marker 基因表达分布点图

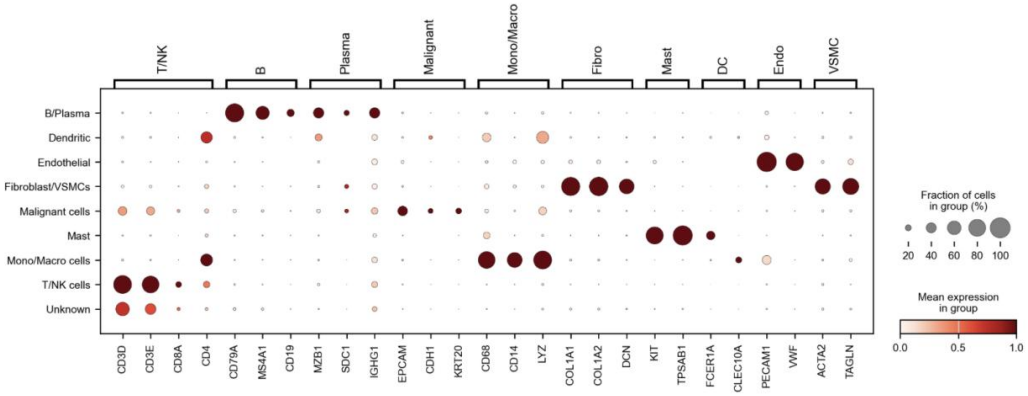

大红点 = 高比例 + 高表达，为正确注释的佐证；若出现小/浅点或空白，则需重新检查该簇身份。整体无异常混杂即表明本次 leiden_1.0 注释结果可靠。

15.不同细胞类型中关键基因的表达模式小提琴图

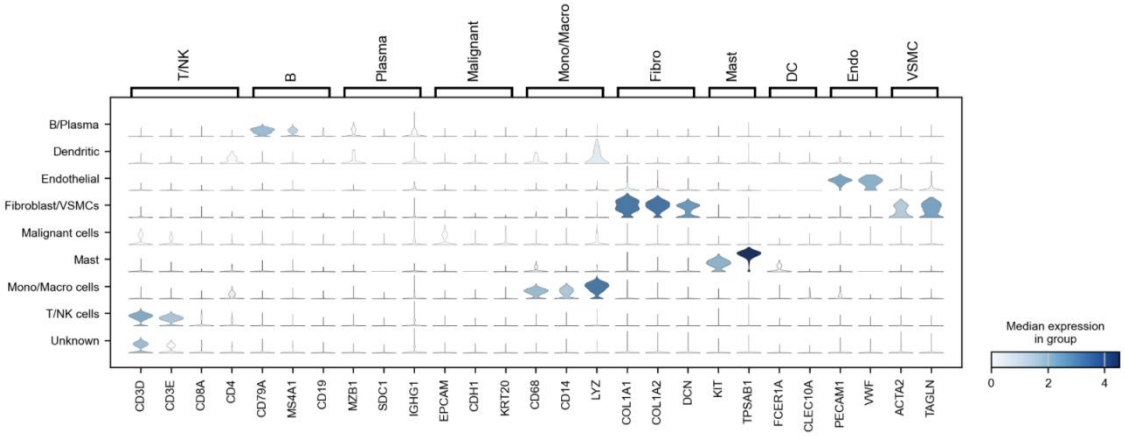

小提琴图展示了不同细胞类型中多个关键基因的表达分布。每个小提琴图表示一个基因在特定细胞类型中的表达密度，颜色深浅表示表达水平的中位数。白点表示中位数表达水平。通过此图可以直观地比较不同细胞类型中基因表达的差异，说明分类大致正确。

16.各细胞类型官方 Top-5 差异基因表达谱（Wilcoxon 检验）

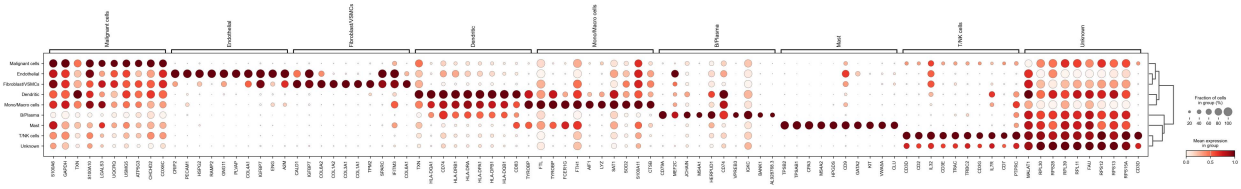

用 Wilcoxon 检验重新挖掘**每组最特异基因，这些新基因与之前手写的经典 marker 高度重合，侧面支持原注释可靠；出现未知基因或新组合，提供细化或修正注释的线索，发现潜在更优标记

17.独立明星基因 UMAP 上色：手工注释质量快速校验

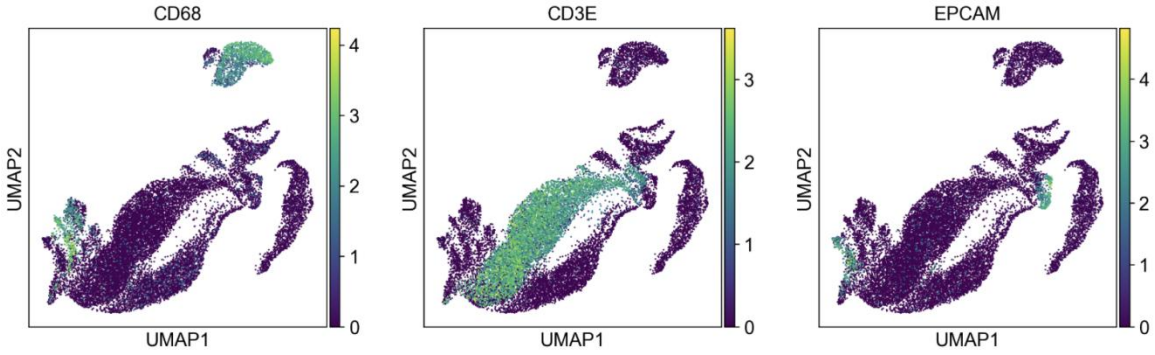

选取巨噬（CD68）、T 细胞（CD3E）、恶性（EPCAM）三个经典 marker 在去批次 UMAP 上独立上色。
颜色越绿 = 表达越高，预期各基因应分别富集于已注释的 Mono、T/NK、Malignant 区域；若出现大片错位，提示需重新检查细胞类型注释或更换 marker。

18.明星基因小提琴分布校验：手工注释特异性评估

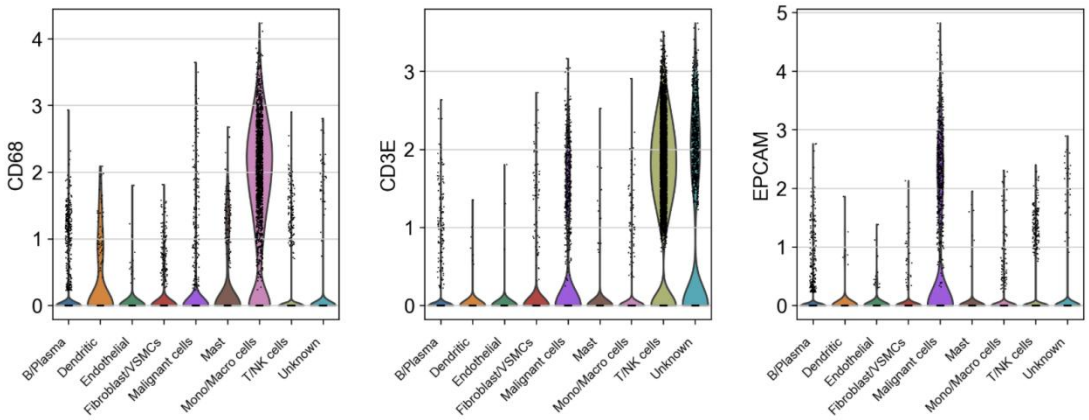

选取 CD68（巨噬）、CD3E（T 细胞）、EPCAM（恶性）三个经典 marker，在去批次 UMAP 坐标基础上按已注释细胞类型绘制小提琴图。高而窄的 violin 表示基因表达专一，矮/宽或长尾伸入别群提示潜在混杂或亚群，可用于快速评估并细化细胞类型注释。